

辞書グラフ位相構造による LLM 概念知識の定量的評価：カーネル縮小とサイクル不可約性のスケーリング

雲居玄道 長岡技術科学大学 kumoi@vos.nagaokaut.ac.jp

要旨

大規模言語モデル (LLM) が生成する定義文から有向定義グラフを構築し, Vincent-Lamarre et al. (2016) の辞書グラフ理論を適用して語彙的自己充足性と概念循環性を定量化した. 3,000 語の英単語に対し, Qwen3.5 (0.8B~27B) と Gemma-4 (4B, 31B) の 2 ファミリー計 7 モデルを分析した結果, 以下の知見を得た.

(1) **スケーリング則**: Qwen3.5 ファミリーでは, カーネル率 (自己完結的核に属する語彙比率) がパラメータ数の対数に対して単調減少し ($r = -0.862$), MinSet/Kernel 比 (カーネル内の不可約サイクル比率) が単調増加する ($r = +0.982$).

(2) **普遍カーネル**: 全 5 モデルで共通してカーネルに現れる 92 語を同定し, うち 10 語が Wierzbicka の自然意味メタ言語 (NSM) 基本表現と重複する.

(3) **指示追従体制 (Instruction Regime)**: 自己参照率 (定義に被定義語が出現する率) はモデルサイズと無関係にファミリー依存であり, Qwen3.5 は 76~92%, Gemma-4 は 0.1% 未満を示す. この差は交絡因子として偏相関分析で制御する必要がある.

(4) **量子化頑健性**: 同一モデルへの 4/6/8 ビット量子化後もカーネル率の変動は $\pm 1\text{pp}$ 以内に収まる.

1. はじめに

LLM は単語の定義文を生成できる. その定義文のネットワーク構造は, LLM がどのように概念を組織しているかを直接反映する可能性がある. 「猫 (cat)」を「毛皮のある動物 (a furry animal)」と定義するとき, そのモデルは「猫」の意味を「毛皮」と「動物」に還元している. こうした還元の連鎖がどこで閉じるか, どこで循環するかは, 概念的自己充足性の指標になる.

辞書グラフ分析の先行研究 (Blondin Massé et al., 2008; Vincent-Lamarre et al., 2016) は, 人間の辞書が特定の構造的性質—カーネル語彙が全体の約 10%, カーネルの約 75% がサイクル構造を持つコアに属する—を持つことを示した. 本研究では, 同じ分析を LLM 生成定義に適用し, モデルサイズ・ファミリー・量子化水準との関係を明らかにする.

研究課題： - RQ1: 定義グラフのカーネル率・循環率はモデルサイズとどう関係するか？ - RQ2: 複数ファミリー間での比較において、指示追従能力（自己参照率）はどのような交絡効果をもたらすか？ - RQ3: 全モデルに共通する普遍カーネルは存在し、意味論的に解釈可能か？

2. 関連研究

2.1 辞書グラフ理論

Vincent-Lamarre et al. (2016) (Topics in Cognitive Science, arXiv:1411.0129) は、辞書を有向グラフとして扱い、3つの核心構造を定式化した：

- **カーネル (Kernel)**：出次数 0 のノードを反復除去して残るサブグラフ。カーネルに属する語は互いの定義の中だけで閉じている (Longman, Cambridge 等の辞書で全体の約 10%)。
- **コア (Core)**：カーネルの縮約 DAG において入次数 0 の SCC の和集合 (「意味の根」)。
- **最小集合 (MinSet / MFVS)**：カーネルの最小フィードバック頂点集合。整数線形計画法で計算 (約 1%)。

辺の向き規約： $(u, v) \in E \implies u$ が v の定義に現れる (u が v を定義する方向)。この規約によりカーネルは「出次数 0 反復除去」で求まる (学習者がよく誤解する入次数との取り違えに注意)。

2.2 LLM のスケーリング則と知識構造

Hoffmann et al. (2022) の Chinchilla スケーリング則は、損失の観点からモデルサイズと学習トークン数の最適配分を与える。知識容量の観点では arXiv:2404.05405 が「1 パラメータあたり約 2 ビットの事実知識」を推定している。本研究は定義ネットワークの位相構造という新しい次元から、スケーリングが概念組織に与える影響を計測する。

2.3 LLM のグラフ推論能力

「Are LLMs Truly Graph-Savvy?» (ACL SRW 2025) はトークン手がかりを除いた純粋なグラフ構造推論において LLM が困難を示すことを報告する。本研究は LLM がグラフを「推論する」能力ではなく、LLM が「生成する」定義が形成するグラフの構造を分析する点で方向性が異なる。

3. 方法

3.1 語彙サンプリング

WordNet から名詞 1,500 語・動詞 900 語・形容詞 600 語の計 3,000 語を抽出した (Brown Corpus 頻度 ≥ 5 でフィルタリング, seed = 42)。頻度フィルタにより、定義内での相互参照が十分に生じる一般語のみを対象とした (300 語では辺がほぼ生じないことを予備実験で確認)。

3.2 定義文生成

各モデルに対して以下のプロンプトを用いた：

Define the {POS} “{word}” in one short sentence. Use only common English words. Do not use the word itself in the definition.

生成パラメータ：temperature = 0.7, top-p = 0.8, top-k = 20, max tokens = 80. 推論は mlx-proxy (Apple M4 Max) を介してローカル実行した。Qwen3.5 の公式 non-thinking モード推奨値 (temperature = 0.7) に従う (temperature = 0.0 は公式に警告されている)。

被定義語そのものが定義文に現れた場合は `self_referential` として記録する (グラフ構築には含めるが自己ループは除去)。

3.3 グラフ構築と指標算出

定義文を小文字化・WordNet レンマ化・ストップワード除去した後、 v の定義に含まれる各レンマ u に対して有向辺 (u, v) を追加する。

計算した指標：

指標	定義
kernel_ratio	$ \text{Kernel} / V $
mset/k	$ \text{MinSet} / \text{Kernel} $
circulation_rate	出次数 ≥ 2 の SCC に属するノード比率
mean_out_degree	語当たりの平均定義使用回数
sr_rate	自己参照定義の比率

MinSet は PuLP + HiGHS ILP で計算 (Apple Silicon では CBC が動作しないため HiGHS を使用)。

4. 結果

4.1 全モデルの指標一覧

表 1：全モデルの定義グラフ指標と指示追従率

モデル	ファミ リー	パラ メータ	指示 追従 %	カー ネル %	mset/k%	循環率 %	平均出 次数
Qwen3.5- 0.8B	Qwen3.5	0.8B	23.8	17.9	14.4	16.7	3.73

モデル	ファミ リー	パラ メータ	指示 追従 %	カー ネル %	mset/k%	循環率 %	平均出 次数
Qwen3.5- 2B	Qwen3.5	2B	7.8	11.1	16.7	6.1	2.66
Qwen3.5- 4B	Qwen3.5	4B	13.8	10.8	17.1	7.5	2.49
Qwen3.5- 9B	Qwen3.5	9B	24.1	10.1	18.1	7.6	2.57
Qwen3.5- 27B	Qwen3.5	27B	15.1	8.6	20.3	6.5	2.52
Gemma- 4-4B	Gemma-4	4B	99.9	7.3	23.3	4.3	—
Gemma- 4-31B	Gemma-4	31B	99.9	8.1	16.2	5.1	—
WordNet (ベース ライン)	—	—	—	15.5	—	7.4	1.67

4.2 Qwen3.5 ファミリー内のスケーリング

カーネル率は単調減少 ($r = -0.862$, $p < 0.05$), mset/k 比は単調増加 ($r = +0.982$, $p < 0.005$).

この解釈：大きなモデルほど定義語彙のより小さな核で他の概念を定義できる（「語彙的効率」の向上）。同時に、その核のサイクル構造はより密になる（不可約循環の増加）。

OLS 回帰 ($\text{kernel_ratio} \sim \log_2(\text{params}) + \text{sr_rate}$, $n=7$) :

$$\text{kernel_ratio} = -0.0165 \times \log_2(B) - 0.0003 \times \text{sr_rate} + 0.200$$

$$R^2 = 0.751$$

sr_rate を偏相関で制御しても $r_{\text{partial}} = -0.723$ ($\Delta r = +0.034$), カーネル率とスケールの関係は自己参照率による見せかけではない。

4.3 普遍カーネル：スケール不変な 92 語

Qwen3.5 全 5 モデルに共通してカーネルに属する語が 92 語存在する（表 2）。

表 2：普遍カーネルのカテゴリ別例

カテゴリ	例
基本動詞	go, hold, move, use, feel, allow, build
関係形容詞	different, flat, high, small, great, correct

カテゴリ	例
認知・概念語	idea, image, true, future, energy
NSM 重複 (10 語)	body, feel, like, people, place, small, time, touch, true, two

NSM との重複は $10/65 = 15.4\%$ (全カーネル語 vs NSM では各モデルで 20~23%). 人間辞書のコアが NSM と 75% 一致する (Vincent-Lamarre et al., 2016) のに比べると低く, LLM の定義スタイルの違いを反映している.

4.4 ファミリー間比較：指示追従体制の交絡効果

Gemma-4 は 99.9% の指示追従率を示し, Qwen3.5 の 76~92% 自己参照率と対照的である. この差は:

1. スケールと無関係: Qwen3.5 ではモデルサイズが増大しても指示追従率に単調傾向はない
2. ファミリー固有: モデルアーキテクチャ・事前学習データの差による

構造的影響: Gemma-4-4B は同パラメータの Qwen3.5-4B より辺が少なく (5,025 vs 6,844), カーネル率も低い (7.3% vs 10.8%). 一方で mset/k は高く (23.3% vs 17.1%), 小さいカーネルがより密な循環構造を持つ.

偏相関分析結果 (sr_rate を制御):

指標	r_生	r_偏 (sr)	Δr
kernel_ratio	- 0.757	- 0.723	+0.034
mset/k	+0.318	+0.388	+0.070

Gemma-4 を含む比較では sr_rate を共変量として報告することを推奨する.

4.5 量子化頑健性

Qwen3.5-27B の各量子化精度:

精度	カーネル %	mset/k%	循環率 %
bf16 (基準)	8.6	20.3	6.5
8-bit	9.4	15.9	5.4
6-bit	8.2	19.1	4.5
4-bit	8.7	20.2	6.5

4-bit が bf16 に最も近い ($\Delta \text{kern} = +0.1\text{pp}$). 8-bit のみ mset/k が大きく低下 ($- 4.4\text{pp}$) し,

MLX の 8-bit 量子化スキーム特有の影響の可能性がある。カーネル率はすべての量子化精度で $\pm 1\text{pp}$ 以内に収まり、グラフ指標は量子化頑健性を示す。

5. 考察

5.1 カーネル縮小と語彙的効率

カーネル率がスケールと逆相関することは、大きなモデルが「より少ない語で多くを定義できる」ことを意味する。これは、大規模モデルが fine-grained な概念表現を持ち、基本語への依存を減らせるという仮説と整合する。

5.2 循環不可約性の増加

mset/k 比の単調増加は、カーネルが縮小しながらも残存するサイクルがより結合度の高いものへと変化することを示す。大規模モデルの概念核は、小規模モデルのそれより位相的に複雑である。

5.3 WordNet との比較

WordNet のカーネル率 (15.5%) は最大の LLM (27B, 8.6%) より高い。Vincent-Lamarre et al. の辞書では約 10% であり、WordNet の高い値はシンセット定義の冗長性によると考えられる。大規模 LLM は人間辞書の計量的特性に近づきつつある。

5.4 限界と今後の課題

- データ点数が少ない (Qwen3.5 $n=5$) ため統計的検出力に限界がある
 - 単一シード (seed=42) のみ；複数シードによる分散評価が必要
 - 日本語辞書への応用と多言語展開
 - 少量の文脈例 (few-shot) を加えたプロンプト実験による sr_rate の制御
-

6. 結論

LLM の生成定義から構成した辞書グラフの位相構造は、モデルスケールの感度の高いプローブとなる。Qwen3.5 ファミリーでは、カーネル率がパラメータ数と逆相関し ($r = -0.862$)、不可約循環比率が正相関する ($r = +0.982$)。92 語の普遍カーネルが 34 倍のパラメータ差を越えて安定し、そのうち 10 語が NSM 基本表現と重複する。ファミリー間比較においては、指示追従体制 (自己参照率) を交絡因子として明示的に管理することが必要である。4 ビット量子化まで、カーネル指標は $\pm 1\text{pp}$ の範囲で安定する。辞書グラフ分析は、損失ベースのスケーリング則を補完する概念知識組織の新しい計量手法として有望である。

参考文献

- Blondin Massé, A., Chicoisne, G., Gargouri, Y., Harnad, S., Picard, O., & Marcotte, O. (2008). How is meaning grounded in dictionary definitions? *Proceedings of TextGraphs-3, ACL/COLING*, 17 – 24.
- Harnad, S., Lepage, M., & Bhatt, R. (2013). Hidden structure and function in the lexicon. *arXiv:1308.2428*.
- Hoffmann, J., et al. (2022). Training compute-optimal large language models. *NeurIPS 2022*.
- Vincent-Lamarre, P., Blondin Massé, A., Lepage, M., Lord, M., Harnad, S., & Marcotte, O. (2016). The latent structure of dictionaries. *Topics in Cognitive Science*, 8(3), 625 – 659.
- Wierzbicka, A. (2021). *Mind, Language and Human Nature*. Mouton de Gruyter.
- Team Qwen (2024). Qwen3 Technical Report. *arXiv:2505.09388*.